# Raport projektowy
# Uczenie się ze wzmocnieniem

Imię i nazwisko studenta

2026/2027

## Spis treści

**1 Informacje podstawowe** **2**

**2 Temat i cel projektu** **2**
2.1 Opis problemu . . . 2
2.2 Cel agenta . . . 2
2.3 Uzasadnienie zastosowania uczenia się ze wzmocnieniem . . . 2

**3 Formalizacja problemu RL/MDP** **3**
3.1 Agent i środowisko . . . 3
3.2 Stan lub obserwacja . . . 3
3.3 Akcje . . . 3
3.4 Funkcja nagrody . . . 4
3.5 Warunki zakończenia epizodu . . . 4
3.6 Założenia i ograniczenia środowiska . . . 5

**4 Implementacja** **5**
4.1 Struktura repozytorium . . . 5
4.2 Środowisko . . . 5
4.3 Agent bazowy . . . 5
4.4 Agent uczący się . . . 5

**5 Plan eksperymentów** **6**

**6 Wyniki** **6**

**7 Analiza i wnioski** **6**

**8 Instrukcja uruchomienia** **7**

**9 Wsparcie AI** **7**

**10 Literatura** **7**

# 1 Informacje podstawowe

| Element | Informacja |
|---|---|
| Imię i nazwisko | Szymon Szymański |
| Numer albumu | 179627 |
| Kierunek/specjalność | Informatyka / Sztuczna Inteligencja |
| Tytuł projektu | Do uzupełnienia |
| Link do repozytorium | https://github.com/vvat55/RLRPG |
| Data oddania | Do uzupełnienia |

# 2 Temat i cel projektu

## 2.1 Opis problemu

Problem badawczy polega na przeprowadzeniu wirtualnego gracza (agenta) przez dwuwymiarowy świat gry RPG podzielony na trzy następujące po sobie lokacje o rosnącym poziomie trudności, zawierające przeszkody, przedmioty i wrogów. Przejście do kolejnej lokacji oraz ukończenie gry jest blokowane przez silnych przeciwników, których pokonanie wymaga posiadania odpowiednio rozwiniętych statystyk bojowych (Atak, Obrona, Zdrowie). Statystyki te agent może zwiększyć wyłącznie poprzez wcześniejsze eksplorowanie poziomów i zbieranie rozlokowanych na niej przedmiotów.

## 2.2 Cel agenta

Celem agenta jest pomyślne przejście wszystkich trzech lokacji i pokonanie finałowego przeciwnika przy zachowaniu dodatniego poziomu punktów życia (HP $> 0$) oraz minimalizacji liczby wykonanych ruchów. Działanie agenta uznaje się za poprawne, gdy potrafi on ukończyć całą grę (dotrzeć do końca 3. lokacji bez śmierci postaci). Działanie uznaje się za skuteczne (optymalne), gdy agent osiąga wysoki odsetek zwycięstw, zbierając wyłącznie przedmioty niezbędne do pokonania kolejnych wyzwań i wybierając najkrótsze bezpieczne ścieżki pomiędzy nimi.

## 2.3 Uzasadnienie zastosowania uczenia się ze wzmocnieniem

Rozważane zagadnienie naturalnie wpisuje się w paradygmat uczenia się ze wzmocnieniem z następujących powodów:

- Sekwencyjne podejmowanie decyzji: W każdym dyskretnym kroku czasowym $t$ agent musi zdecydować, w którym kierunku się poruszyć. Ciąg tych elementarnych ruchów składa się na wyższą strategię: czy iść prosto do wyjścia z lokacji, czy zboczyć z trasy po przedmiot ulepszający, czy też ominąć opcjonalnego przeciwnika.
- Wpływ decyzji na przyszły stan środowiska: Każda akcja trwale modyfikuje stan gry. Zebranie przedmiotu bezpowrotnie usuwa go z poziomu i na stałe podnosi statystyki agenta, a stoczenie walki trwale obniża punkty zdrowia (HP), co bezpośrednio determinuje szanse przeżycia w kolejnych lokacjach.

- Znaczenie wyniku długoterminowego ponad natychmiastową nagrodą: Podejście zachłanne (np. minimalizacja dystansu do wyjścia lub unikanie wszelkich walk) prowadzi do szybkiej porażki – nieulepszony agent zginie przy pierwszym przeciwniku lub w kolejnej, trudniejszej lokacji. Agent musi nauczyć się ponosić krótkoterminowy koszt (kara za dodatkowe kroki i utrata części HP podczas eksploracji pobocznych ścieżek), aby zyskać statystyki gwarantujące wysoką nagrodę długoterminową (ukończenie gry).
- Zasadność użycia agenta uczącego się: Wraz z dodawaniem kolejnych lokacji, przedmiotów i pułapek, ręczne zaprojektowanie reguł określających, które przedmioty opłaca się zebrać przy danym poziomie HP, staje się nieefektywne i mało elastyczne. Agent RL potrafi samodzielnie odkryć optymalny balans między eksploracją (zbieraniem ekwipunku) a eksploatacją (parciem do celu) na podstawie samej interakcji ze środowiskiem.

# 3 Formalizacja problemu RL/MDP

## 3.1 Agent i środowisko

Środowiskiem jest deterministyczna gra 2D oparta na siatce (gridzie) o wymiarach $N \times M$, podzielona na 3 odrębne poziomy (lokacje). Interakcja przebiega w dyskretnych krokach czasowych $t = 0, 1, 2, \ldots, T$. W każdym kroku $t$ agent odczytuje ze środowiska aktualny stan $s_t \in S$, wybiera akcję $a_t \in A$, na co środowisko odpowiada przejściem do nowego stanu $s_{t+1} \in S$ oraz wygenerowaniem skalarnego sygnału nagrody $r_t \in \mathbb{R}$.

## 3.2 Stan lub obserwacja

Zakładamy środowisko w pełni obserwowalne (brak różnicy między stanem faktycznym środowiska a obserwacją dostępną dla agenta: $o_t = s_t$). Stan $s_t$ jest reprezentowany jako wektor cech:

$$s_t = [L, x, y, \mathrm{HP}, \mathrm{ATK}, \mathrm{DEF}, b_1, b_2, \ldots, b_k]$$

, gdzie:

- $L \in \{1, 2, 3\}$ – numer aktualnej lokacji,
- $x, y$ – aktualne współrzędne agenta na siatce danej lokacji,
- $\mathrm{HP}, \mathrm{ATK}, \mathrm{DEF}$ – aktualne wartości punktów zdrowia, ataku i obrony agenta,
- $b_1, \ldots, b_k \in \{0, 1\}$ – flagi binarne określające obecność kluczowych przedmiotów oraz przeciwników na mapie (1 – obiekt aktywny na mapie, 0 – obiekt zebrany/pokonany).

## 3.3 Akcje

Zbiór akcji jest dyskretny i obejmuje 4 podstawowe kierunki ruchu na siatce:

$$A = \{\text{Góra}, \text{Dół}, \text{Lewo}, \text{Prawo}\}$$

Interakcje ze światem (podniesienie przedmiotu, walka z wrogiem, przejście przez portal do kolejnej lokacji) następują automatycznie w momencie wejścia na odpowiednie pole.

**Akcje niedozwolone / zablokowane:** Wejście na pole stanowiące ścianę (przeszkodę statyczną) lub wyjście poza granice siatki mapy. W środowisku można to obsłużyć na dwa sposoby: poprzez maskowanie akcji (uniemożliwienie ich wyboru) lub poprzez zachowanie pozycji agenta w miejscu ($x_{t+1} = x_t, y_{t+1} = y_t$) przy jednoczesnym naliczeniu kary.

## 3.4 Funkcja nagrody

Funkcja nagrody w kroku $t$ jest zdefiniowana następująco:

$$r_t = \begin{cases} +100.0 & \text{za pokonanie finałowego przeciwnika (ukończenie Lokacji 3),} \\ +25.0 & \text{za przejście do kolejnej lokacji (ukończenie Lokacji 1 lub 2),} \\ +5.0 & \text{za zebranie przedmiotu zwiększającego statystyki,} \\ -50.0 & \text{za śmierć postaci (spadek HP} \leq 0\text{),} \\ -1.0 & \text{za próbę wejścia w ścianę lub wyjścia poza mapę,} \\ -0.1 & \text{za każdy standardowy krok czasowy (ruch).} \end{cases}$$

W tej sekcji należy wyjaśnić:

- Nagrody dodatnie i kary: Główny cel (+100) dominuje nad pozostałymi wartościami, gwarantując, że priorytetem jest ukończenie gry. Nagrody pośrednie (+25 za lokację, +5 za przedmiot) zagęszczają sygnał wzmacniający (reward shaping), ułatwiając agentowi powiązanie faktu zbierania ekwipunku z możliwością przejścia dalej. Wysoka kara za śmierć (-50) zmusza agenta do unikania walk, na które nie jest jeszcze gotowy statystycznie.
- Kara za krok: Stała opłata $-0.1$ za każdy ruch wymusza znajdowanie najkrótszych ścieżek i zapobiega bezcelowemu kręceniu się po bezpiecznych polach.
- Ograniczenia twarde i miękkie: Ograniczeniem twardym jest geometria mapy (brak możliwości przenikania przez ściany) oraz brak możliwości powrotu do poprzedniej lokacji po przekroczeniu portalu. Ograniczeniem miękkim (realizowanym przez system kar i mechanikę walki) jest wymóg posiadania odpowiednich statystyk przed zaatakowaniem strażnika – agent formalnie może zaatakować strażnika od razu, ale skończy się to utratą całego HP i karą $-50$.
- Zapobieganie niepożądanym zachowaniom: Dzięki binarnym flagom stanu $b_i$, każdy przedmiot można zebrać tylko raz. Suma wszystkich nagród za przedmioty na mapie jest mniejsza niż nagroda za ukończenie gry, a brak odnawiania się przedmiotów uniemożliwia agentowi nieskończone naliczanie punktów (+5) w jednej lokacji.

## 3.5 Warunki zakończenia epizodu

Epizod ulega natychmiastowemu zakończeniu w trzech przypadkach:

- Sukces: Agent pokonuje finałowego przeciwnika w Lokacji 3 i dociera do pola końcowego.
- Porażka: Punkty zdrowia agenta spadną do zera lub poniżej (HP $\leq 0$) w wyniku walki lub wejścia w pułapkę.
- Przekroczenie limitu czasu: Licznik kroków w epizodzie osiągnie maksymalną wartość $T_{\max}$, co zapobiega zawieszeniu treningu we wczesnej fazie nauki.

### 3.6 Założenia i ograniczenia środowiska

W celu zachowania przejrzystości badawczej i dopasowania do ram przyjęto następujące uproszczenia:

- Deterministyczna, natychmiastowa walka: Zamiast osobnego ekranu walki turowej, starcie z przeciwnikiem jest rozstrzygane w jednym kroku czasowym za pomocą deterministycznej formuły matematycznej (przykładowo: $\Delta\text{HP} = \max(0, \text{HP}_{\text{wroga}} \cdot (\text{ATK}_{\text{wroga}} - \text{DEF}_{\text{agenta}})/\text{ATK}_{\text{agenta}})$).
- Brak aktywnego zarządzania ekwipunkiem: Przedmioty po podniesieniu natychmiastowo i trwale zwiększają statystyki (brak plecaka, brak konieczności zakładania przedmiotów czy limitów ich ilości).
- Statyczność przeciwników: Wrogowie i strażnicy stoją na przypisanych polach (wąskich gardłach mapy), co redukuje losowość środowiska i ułatwia analizę zbieżności algorytmu. , Elementy pominięte: W modelu pominięto złożone mechaniki rozwoju lub handlu (rozwój odbywa się wyłącznie przez eksplorację i przedmioty), złożonych systemów walki oraz ciągłą fizykę ruchu (zastąpioną dyskretną siatką 2D).

# 4 Implementacja

## 4.1 Struktura repozytorium

Należy krótko opisać strukturę repozytorium i najważniejsze pliki projektu.

```
repozytorium/
|-- src/
|-- experiments/
|-- report/
|-- results/
‘-- README.md
```

## 4.2 Środowisko

Należy opisać sposób implementacji środowiska, w szczególności funkcje inicjalizacji epizodu oraz wykonania kroku środowiska.

## 4.3 Agent bazowy

Należy opisać agenta losowego, heurystycznego albo inny baseline wykorzystany do porównania z agentem uczącym się.

## 4.4 Agent uczący się

Należy opisać zastosowany algorytm RL lub DRL, jego parametry oraz sposób implementacji. W przypadku Q-tab należy opisać reprezentację tablicy wartości. W przypadku DRL należy opisać wejścia modelu, wyjścia modelu, architekturę oraz sposób uczenia.

# 5 Plan eksperymentów

Należy opisać eksperymenty zaplanowane w celu oceny działania agenta.

| Eksperyment | Co jest zmieniane? | Co jest mierzone? |
|---|---|---|
| E1 | Do uzupełnienia | Do uzupełnienia |
| E2 | Do uzupełnienia | Do uzupełnienia |
| E3 | Do uzupełnienia | Do uzupełnienia |

W tej sekcji należy wskazać:

- liczbę epizodów uczenia,
- liczbę powtórzeń eksperymentu albo uzasadnienie braku powtórzeń,
- parametry uczenia,
- metryki oceny,
- warianty środowiska, map lub funkcji nagrody,
- sposób porównania z agentem bazowym.

# 6 Wyniki

W tej sekcji należy przedstawić wyniki eksperymentów. Wyniki powinny być pokazane w postaci tabel, wykresów lub czytelnych zestawień.

| Wariant | Średni zwrot | Skuteczność | Długość epizodu |
|---|---|---|---|
| Agent bazowy | Do uzupełnienia | Do uzupełnienia | Do uzupełnienia |
| Agent RL/DRL | Do uzupełnienia | Do uzupełnienia | Do uzupełnienia |




Rysunek 1: Przykładowy wykres procesu uczenia agenta.

# 7 Analiza i wnioski

Należy zinterpretować wyniki. W tej części należy odpowiedzieć m.in. na pytania:

- Czy agent uczący się działa lepiej niż agent bazowy?
- Jak zmieniało się zachowanie agenta w trakcie uczenia?
- Które elementy środowiska były najtrudniejsze?
- Czy funkcja nagrody prowadziła do oczekiwanego zachowania?
- Czy wystąpiły przypadki niepożądanego zachowania agenta?
- Jakie są najważniejsze ograniczenia rozwiązania?

# 8 Instrukcja uruchomienia

Należy opisać sposób uruchomienia projektu od czystego repozytorium. Przykładowo:

```
git clone https://github.com/...
cd nazwa-repozytorium
python -m venv .venv
.venv\Scripts\activate
pip install -r requirements.txt
python src/main.py
```

Należy również wskazać, jak odtworzyć eksperymenty oraz gdzie zapisywane są wyniki.

# 9 Wsparcie AI

W tej sekcji należy obowiązkowo opisać wykorzystanie narzędzi sztucznej inteligencji. Jeżeli student nie korzystał z takich narzędzi, należy wpisać jednoznaczną informację, że nie korzystano ze wsparcia AI.

| Data | Narzędzie/model | Cel użycia | Transkrypt / link / zakres |
|---|---|---|---|
| Do uzupełnienia | Do uzupełnienia | Do uzupełnienia | Do uzupełnienia |
| Do uzupełnienia | Do uzupełnienia | Do uzupełnienia | Do uzupełnienia |

Należy zapisać transkrypty rozmów z modelami AI wraz z datą oraz nazwą modelu. Jeżeli rozmowa odbywała się poza narzędziami programistycznymi, należy dodatkowo udostępnić całą rozmowę poprzez link, o ile użyte narzędzie umożliwia takie udostępnienie.

Student powinien także wyjaśnić, które elementy wygenerowane lub zasugerowane przez AI zostały samodzielnie sprawdzone, zmodyfikowane albo odrzucone.

# 10 Literatura

W tej sekcji należy wskazać wykorzystane źródła: książki, artykuły naukowe, dokumentację bibliotek, materiały wykładowe oraz inne źródła użyte podczas pracy nad projektem.

# Literatura

[1] R. S. Sutton, A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed., MIT Press, 2018.